Detección y exclusión de variables circulares en un modelo de ingreso a UCI, sobre un log de eventos de sepsis

Jessica Melani Romero Lora · Maestría en Ingeniería en Inteligencia Artificial · Director: Dr. Marcos Yamir Gómez

1. Estado del arte

El estado del arte reúne 27 referentes en dos bloques: minería de procesos en salud y sepsis (15) y fuga de datos en aprendizaje automático (12). La tabla completa, con objetivo relacionado, aporte por referencia y estado de verificación, está en el libro Estado_del_Arte_v3.xlsx. La búsqueda documentada (base de datos, cadena de búsqueda, fechas y criterios) está pendiente de completar.

2. Planteamiento del problema

En contextos clínicos, los modelos predictivos que anticipan ingresos a unidades de cuidados intensivos (UCI) son herramientas críticas para el triaje y la asignación de recursos. Sin embargo, la precisión reportada de estos modelos frecuentemente se ve inflada por la inclusión de **variables circulares**: aquellas que contienen información del propio desenlace que se intenta predecir, ya sea porque se registran después del evento de interés, porque definen operacionalmente el desenlace o porque actúan como proxies fuertes del mismo.

Este problema, conocido como fuga de información o circularidad, es particularmente difícil de detectar en conjuntos de datos tabulares convencionales. No obstante, en logs de eventos clínicos —registros cronológicos que documentan el orden de todas las actividades y sus marcas de tiempo— es posible identificar sistemáticamente cuáles variables se registraron antes o después del ingreso a UCI, permitiendo así su clasificación como circulares o no circulares.

El problema central que aborda este trabajo es doble: (1) desarrollar un procedimiento para detectar variables circulares aprovechando el orden temporal en trazas de eventos, y (2) cuantificar cuánto la exclusión de estas variables modifica el desempeño real de un modelo de predicción de ingreso a UCI, revelando así en qué medida la circularidad había inflado las métricas reportadas.

3. Pregunta de investigación

¿En qué medida la exclusión de variables circulares influye en el desempeño predictivo del ingreso a UCI, en el log Sepsis Cases de un hospital de Países Bajos registrado entre noviembre de 2013 y junio de 2015?

Elemento	Definición en este estudio
1. Pregunta clave	Influencia de la exclusión de variables circulares en el desempeño predictivo
2. Variable x	Exclusión de variables circulares (modelo base frente a modelo corregido)
3. Enlace	Influye en (magnitud del efecto)
4. Variable y	Desempeño predictivo del ingreso a UCI (área bajo la curva y recall)
5. Muestra / población	1,050 casos del log; 110 con ingreso a UCI (~10%)
6. Ámbito de datos	Log de eventos clínicos de um sistema ERP hospitalario, de acceso público
7. Ámbito geográfico (objetivo)	Un hospital de Países Bajos
8. Tiempo	Noviembre de 2013 a junio de 2015

4. Objetivo general

Analizar cómo la exclusión de variables circulares modifica el desempeño predictivo de un modelo de ingreso a UCI en un log de eventos de sepsis.

5. Objetivos específicos

OE1. Examinar la posición temporal de cada variable respecto al ingreso a UCI dentro de cada traza, para clasificarla como circular o no circular.

OE2. Cuantificar la diferencia de área bajo la curva y de recall entre el modelo base y el modelo corregido, con validación cruzada anidada e intervalos de confianza.

OE3. Contrastar la precisión y el recall del procedimiento de detección frente a variables con fuga inyectada de intensidad conocida.

Relación con el general: OE1 define la variable x, OE2 mide su efecto sobre y, y OE3 valida que x esté bien clasificada.

6. Justificación

6.1 Relevancia social

La sepsis es una causa relevante de ingreso a unidades de cuidados intensivos, y los modelos que anticipan ese ingreso pueden apoyar el triaje. Un modelo cuya precisión está inflada por circularidad puede orientar mal esas decisiones. Medir el efecto real de la circularidad protege contra esa decisión Mannhardt y Blinde (2017).

6.2 Conveniencia

El procedimiento usa un log público ya disponible, herramientas abiertas (scikit-learn, XGBoost, PM4Py) y un desenlace bien definido. Es ejecutable en el plazo de un posgrado y no requiere acuerdos institucionales. Desde el punto de vista técnico, la fuga de información está documentada como problema común en aprendizaje automático (Kapoor y Narayanan, 2023), y en logs de eventos el orden de las actividades ofrece una forma sistemática de detectarla.

6.3 Valor teórico

El estudio relaciona dos líneas que rara vez se cruzan: la literatura sobre fuga de datos en aprendizaje automático y la de minería de procesos en salud. La contribución teórica es un criterio operativo para clasificar variables según su posición en la traza, validado en un log real y en uno con fugas inyectadas.

6.4 Implicaciones prácticas

Si la corrección reduce el desempeño de forma relevante, los modelos reportados con este tipo de log pueden estar sobreestimados. El procedimiento puede reutilizarse en otros logs con desenlaces de ingreso o alta. Los resultados no se generalizan a otros hospitales sin validación externa.

7. Hipótesis de investigación e hipótesis nula

H1: el área bajo la curva del modelo corregido es menor que la del modelo base. Esta dirección se espera por la evidencia de fuga en la literatura (Kapoor y Narayanan, 2023).

H0: no hay diferencia en el área bajo la curva entre el modelo base y el modelo corregido, más allá de la variación esperada por el muestreo.

Algoritmos: regresión logística, Random Forest y XGBoost, con la misma validación. Métricas principales: área bajo la curva (variante por confirmar: precisión-recall o ROC) y recall.

8. Marco teórico

El marco se organiza en cuatro bloques, que corresponden a los temas de la siguiente sección. La fuga de información se define por escenarios (definicional, temporal y por proxy) y se mide con el efecto sobre el desempeño. La minería de procesos ofrece la representación de trazas que permite ubicar cada variable en el tiempo. La validación de modelos y la calidad de datos completan el procedimiento.

9. Temas del marco teórico

Tema	Referentes en la tabla	Objetivo
9.1 Fuga de información: escenarios, medición y efecto	#16, #18, #22, #23, #24, #28, #42	OE1, OE2, OE3
9.2 Validación de modelos y pipelines (incluye validación anidada)	#17, #19, #21, #29, #38	OE2
9.3 Minería de procesos: representación y orden de trazas en salud y sepsis	#1, #2, #8, #9, #11, #13, #15, #31, #32, #33, #34, #35, #37, #43, #44, #45, #46	OE1
9.4 Detección automática de fuga	#25, #26, #41	OE3
9.5 Calidad de datos y limpieza	#20, #27	Marco general
9.6 Algoritmos de clasificación	#21, #30, #39, #40; pendiente: referencia metodológica de Random Forest (Breiman, 2001) y de regresión logística	OE2

Nota: todas las referencias están pendientes de verificación bibliográfica completa (volumen, páginas, DOI) antes de la entrega.

10. Relación del marco teórico con los objetivos y el estado del arte

Cada tema del marco sustenta al menos un objetivo. La columna de pendientes indica lo que el marco aún no cubre con referentes verificados.

Objetivo	Temas del marco que lo sustentan	Referentes (tabla)	Pendiente de fuente
General	9.1, 9.2, 9.3	#1, #2, #16, #22, #23, #24	Ninguno adicional: el general integra los tres objetivos.
OE1. Examinar la posición temporal de cada variable	9.1 (circularidad temporal y definicional), 9.3 (orden de actividades en la traza)	#1, #2, #8, #9, #13, #15, #16, #22, #28, #42	Definición operativa de "circular" y umbral del criterio proxy: referencias identificadas, pendientes de incorporar a la tabla.
OE2. Cuantificar la diferencia de área bajo la curva y recall	9.1 (efecto de la fuga sobre métricas), 9.2 (validación y pipelines)	#17, #19, #21, #23, #24, #29, #30, #38, #39, #40	Referencia metodológica de Random Forest (Breiman, 2001) y de regresión logística; las de aplicación ya están (#39, #40).
OE3. Contrastar la precisión y recall del detector	9.1 (medición de fuga), 9.4 (detección automática)	#18, #25, #26, #41	Definición de precisión y recall del detector; el método de inyección

			tiene referencia por analogía (#41).

Relación con el estado del arte: el bloque de fuga de datos (12 referentes) sustenta OE1, OE2 y OE3; el bloque de minería de procesos en salud (15 referentes) sustenta OE1 y la justificación social. Los temas 9.5 (calidad de datos) y el marco general sostienen la preparación del log.

Alcance del componente de procesos: la minería de procesos se usa para representar y ordenar las trazas, que es lo que requiere OE1. El descubrimiento de modelos de proceso y el cálculo de fitness no forman parte de los objetivos vigentes y no se desarrollan en el marco.

Pendientes de incorporar o verificar:

- Definición operativa de circularidad: más de tres referentes identificados, pendientes de incorporar a la tabla.
- Referencia metodológica de Random Forest (Breiman, 2001) y de regresión logística; las referencias de aplicación ya están en la tabla.
- Métricas de precisión del detector (definición formal).
- Pasaje y página exacta de la fuente de relevancia social (Mannhardt y Blinde, 2017).