Estado del arte

La calidad de los datos de origen condiciona el desempeño de los modelos de aprendizaje automático sobre datos tabulares (**Mohammed et al. (2025)**). En el ámbito clínico, los algoritmos se han propuesto para apoyar decisiones de clasificación y asignación de recursos en sepsis: **Adjerid et al. (2023)** estudiaron el valor de la innovación de procesos habilitada por algoritmos en este contexto, y **Mannhardt y Blinde (2017)** reconstruyeron la trayectoria de 1,050 pacientes con sepsis de un hospital de Países Bajos, desde el registro en urgencias hasta el alta.

La fuga de información ocurre cuando un modelo utiliza, durante el entrenamiento o la evaluación, información que no existiría al momento de la predicción. **Kaufman et al. (2011)** formalizaron este problema en minería de datos y propusieron estrategias para detectarlo y evitarlo. **Kapoor y Narayanan (2023)** documentaron que la fuga afecta al menos a 294 artículos en 17 disciplinas, propusieron una taxonomía de ocho tipos y mostraron que, al corregirla, modelos complejos reportados como superiores dejan de superar de forma sustancial a métodos estadísticos más simples.

Sasse et al. (2025) presentaron una revisión de los escenarios de fuga en aprendizaje supervisado. **Rosenblatt et al. (2024)** cuantificaron empíricamente cómo la fuga por selección de variables y por sujetos repetidos infla el desempeño de los modelos predictivos. En el plano metodológico, **Kriegeskorte et al. (2009)** definieron el análisis circular (double dipping), y **Cawley y Talbot (2010)** demostraron el sesgo optimista que surge cuando la selección del modelo no está anidada dentro de la evaluación.

Para cuantificar la fuga, **Hannun et al. (2021)** proponen medirla en modelos mediante información de Fisher. En cuanto a la detección automática, **Yang et al. (2022)** desarrollaron un análisis estático para identificar fugas en cuadernos de ciencia de datos, y **Alomar et al. (2025)** propusieron una herramienta de código abierto con el mismo fin. Ambos trabajos se enfocan en errores del código del procesamiento; ninguno evalúa si una variable es circular por su posición temporal respecto al desenlace.

En salud, **Rojas et al. (2016)** y **Aversano et al. (2025)** documentan el uso creciente de la minería de procesos para describir trayectorias de pacientes, verificar la conformidad con guías clínicas y detectar cuellos de botella. **Quintano Neira et al. (2020)** y **Silva Júnior et al. (2023)** aportan procedimientos sobre rutas clínicas de sepsis, y **Rebuge y Ferreira (2012)** y **Pereira et al. (2020)** describen metodologías replicables para proyectos de minería de procesos en hospitales.

Esta línea de investigación se centra en el descubrimiento y la conformidad del proceso ejecutado. **Mannhardt y Blinde (2017)**, **Rojas et al. (2016)** y **Aversano et al. (2025)** no utilizan el orden de las trazas para decidir qué variables son legítimas como predictores, ni examinan la circularidad de los atributos.

Con base en los trabajos citados en este apartado (**Kaufman et al. (2011)**, **Kapoor y Narayanan (2023)**, **Yang et al. (2022)**, **Alomar et al. (2025)**, **Rojas et al. (2016)** y **Mannhardt y Blinde (2017)**), no se identificó ningún trabajo que combine el orden temporal de un log de eventos con la detección de variables circulares en un modelo predictivo clínico, ni que valide esa detección frente a fugas de intensidad conocida. La presente investigación se sitúa en esa intersección.

Planteamiento del problema

Problemática

En los hospitales, los modelos predictivos que anticipan el ingreso de un paciente a la unidad de cuidados intensivos (UCI) se proponen como apoyo para el proceso de clasificación y la asignación de recursos (Adjerid et al., 2023; Mannhardt y Blinde, 2017). Sin embargo, su desempeño reportado puede estar sobreestimado si el modelo utiliza variables circulares, es decir, variables que contienen información del propio desenlace que se intenta predecir (Kapoor y Narayanan, 2023; Kaufman et al., 2011).

Una variable puede ser circular por tres vías: porque define operacionalmente el desenlace (circularidad definicional), porque se registra después del evento de interés y, por lo tanto, no está disponible en el momento de la predicción (circularidad temporal), o porque actúa como sustituto fuerte del desenlace (circularidad proxy) (Kapoor y Narayanan, 2023; Kaufman et al., 2011). Un modelo entrenado con estas variables mide en parte su propia consecuencia y no su capacidad real de anticipar el ingreso a UCI (Kapoor y Narayanan, 2023).

Esta fuga de información es difícil de detectar. Las herramientas disponibles revisan errores en el código del procesamiento (Yang et al., 2022; Alomar et al., 2025) y no el momento en que se registró cada atributo. Los logs de eventos clínicos sí documentan el orden de las actividades y sus marcas de tiempo, como el log Sepsis Cases (Mannhardt, 2016), por lo que permiten verificar si una variable se registró antes o después del ingreso a UCI. Sin embargo, en las revisiones sobre minería de procesos en salud, ese orden se ha empleado para describir trayectorias y verificar conformidad, y no para decidir qué predictores son legítimos a nivel metodológico o de diseño del pipeline de datos (Rojas et al., 2016; Aversano et al., 2025).

La importancia de la exclusión de variables circulares responde a la necesidad de diseñar sistemas de ingesta y procesamiento de datos para el sector salud, donde la medicina y el despliegue de modelos de inteligencia artificial convergen. Estos sistemas permiten clasificar de forma auditada a los pacientes según su probabilidad de ingreso a la UCI, lo que hace indispensable que las métricas reportadas reflejen únicamente la información disponible al momento de la decisión.

El diseño de un sistema de inteligencia artificial que incorpore minería de procesos, con énfasis en la auditabilidad del pipeline, tiene como propósito evitar que las métricas de los modelos seleccionados sean engañosas: Random Forest (Breiman, 2001), XGBoost (Chen y Guestrin, 2016) y regresión logística (Hosmer et al., 2013).

Por tanto, el presente trabajo se delimita al log Sepsis Cases, con 1,050 casos, 15,214 eventos y 110 casos con ingreso a UCI (10.5 %), registrados en un hospital de Países Bajos entre noviembre de 2013 y junio de 2015 (Mannhardt, 2016). En este sentido, se plantea desarrollar un procedimiento que detecte variables circulares a partir del orden temporal de las trazas, y cuantificar en qué medida la exclusión de esas variables modifica el desempeño de un modelo de ingreso a UCI.

Pregunta de investigación

¿En qué medida la exclusión de variables circulares modifica el desempeño predictivo (área bajo la curva y recall) de un modelo de ingreso a la unidad de cuidados intensivos construido con la información disponible en el registro en urgencias, en el log de eventos clínicos Sepsis Cases de un hospital de Países Bajos, con datos registrados entre noviembre de 2013 y junio de 2015?

Objetivo general

Analizar cómo la exclusión de variables circulares modifica el desempeño predictivo de un modelo de ingreso a UCI construido con la información disponible en el registro en urgencias, a partir del log de eventos Sepsis Cases.

Objetivos específicos

• Examinar la posición temporal de cada variable respecto al ingreso a UCI dentro de cada traza, para clasificarla como circular o no circular.

• Cuantificar la diferencia de área bajo la curva (AUC) y de recall entre el modelo base y el modelo corregido, con validación cruzada anidada e intervalos de confianza por bootstrap.

• Contrastar la precisión y el recall del procedimiento de detección frente a variables con fuga inyectada de intensidad conocida.

Hipótesis

La exclusión de las variables circulares reducirá el área bajo la curva (AUC) del modelo de ingreso a UCI respecto al modelo base, lo que implicaría que la circularidad infla el desempeño reportado en el log Sepsis Cases (Kapoor y Narayanan, 2023; Rosenblatt et al., 2024).

Justificación

Relevancia social

La sepsis es una causa relevante de ingreso a las unidades de cuidados intensivos, y los modelos que anticipan ese ingreso pueden apoyar las decisiones de triaje desde urgencias (Mannhardt y Blinde, 2017; Adjerid et al., 2023). Un modelo cuya precisión está inflada por circularidad puede orientar esas decisiones de manera errónea, al aparentar una capacidad de anticipación que no tendría en la práctica. Medir el efecto real de la circularidad contribuye a que los modelos utilizados durante la clasificación se evalúen con la información realmente disponible al momento de decidir.

Conveniencia

Esta investigación propone un procedimiento metodológico que integra minería de procesos, aprendizaje automático y validación con fugas inyectadas para detectar y excluir variables circulares en modelos de predicción del ingreso a UCI a partir de logs de eventos clínicos.

El procedimiento utiliza un log público y desidentificado con un desenlace bien definido (Admission IC), por lo que no requiere acuerdos institucionales ni acceso a datos personales (Mannhardt, 2016). Su alcance, un log, un hospital y un desenlace, lo hace ejecutable en el plazo de un programa de posgrado.

Además, el orden de las actividades permite detectar la fuga de forma sistemática, un problema reconocido como común en el aprendizaje automático (Kapoor y Narayanan, 2023). El procedimiento se apoya en herramientas abiertas: XGBoost (Chen y Guestrin, 2016) y PM4Py (Berti et al., 2019).

Aporte teórico

La investigación vincula dos líneas que rara vez se cruzan: la literatura sobre fuga de información en aprendizaje automático (Kaufman et al., 2011; Kapoor y Narayanan, 2023) y la minería de procesos en salud (Rojas et al., 2016;

Mannhardt y Blinde, 2017). Su contribución es un criterio operativo para clasificar variables según su posición en la traza respecto al desenlace. Este criterio distingue la circularidad definicional, temporal y proxy, y se valida tanto en un log real como en un log con fugas inyectadas de intensidad conocida.

Implicaciones prácticas

Durante el desarrollo del protocolo de investigación se identificaron estudios basados en bases de datos clínicas que contienen trazas, logs de eventos y características de pacientes registradas de forma ordenada y documentada. Estas bases permiten comparar el desempeño de modelos con y sin variables circulares, siempre que la circularidad se detecte durante el diseño del pipeline y no después de la evaluación.

La base de datos Sepsis Cases (Mannhardt, 2016) cumple las características necesarias para construir pipelines comparativos que detecten circularidad en las variables principales. Si la corrección reduce el desempeño de forma relevante, los modelos reportados con este tipo de log podrían estar sobreestimados, lo que obligaría a revisar las métricas publicadas (Kapoor y Narayanan, 2023).

El procedimiento es reutilizable en otros logs de eventos con desenlaces de ingreso o de alta. La validación con fugas inyectadas permite estimar la precisión y el recall del detector antes de aplicarlo a datos nuevos. No obstante, es fundamental reconocer que los resultados obtenidos no son generalizables a otros hospitales sin una validación externa y especializada.

Marco teórico

Examinar la posición temporal de cada variable respecto al ingreso a UCI dentro de cada traza, para clasificarla como circular o no circular.

2.1. Fuga de información y circularidad de variables en la predicción del ingreso a UCI.

El primer objetivo específico exige definir qué es una variable circular y establecer un criterio verificable para identificarla. Esta sección presenta los conceptos necesarios: la fuga de información, la clasificación de la circularidad y el uso del orden temporal de un log de eventos como criterio de medición.

2.1.1. Fuga de información en el aprendizaje supervisado.

Una fuga de información ocurre cuando un modelo utiliza, durante el entrenamiento o la evaluación, datos que no estarían disponibles en el momento

de la predicción. Kaufman et al. (2011) la formalizaron en minería de datos, y Kapoor y Narayanan (2023) mostraron que es un problema extendido en la ciencia basada en aprendizaje automático. Su efecto es más grave en la evaluación, porque el desempeño reportado resulta mayor que el que el modelo tendría en la práctica.

2.1.2. Clasificación de la circularidad.

Una variable es circular cuando contiene información del propio desenlace. Se distinguen tres tipos:

• Circularidad definicional: la variable define operacionalmente el desenlace.

• Circularidad temporal: la variable se registra después del evento de interés y, por lo tanto, no está disponible en el momento de la predicción.

• Circularidad proxy: la variable actúa como sustituto fuerte del desenlace, aunque no lo defina ni se registre después de él.

La circularidad temporal es la única de las tres que puede verificarse directamente con las marcas de tiempo de un log. Las otras dos requieren evidencia documental sobre la definición de cada variable. Por ello, el criterio del objetivo específico 1 se aplica primero a la posición temporal y después se complementa con la documentación del log.

2.1.3. Log de eventos y posición temporal de los atributos.

Un log de eventos es un registro en el que cada evento corresponde a una actividad ejecutada en un caso, con su marca de tiempo y sus atributos. La secuencia ordenada de eventos de un caso constituye su traza (van der Aalst, 2016). Esta representación permite ubicar, para cada atributo, el momento en que se registró respecto al ingreso a UCI (Admission IC).

Con esta referencia, un valor de atributo se considera posterior al desenlace si su marca de tiempo es mayor que la marca de Admission IC del mismo caso. Un valor es elegible como predictor si su marca es menor o igual a la del momento de predicción, que en este estudio corresponde al registro en urgencias (ER Registration). El descubrimiento de modelos de proceso no forma parte de este objetivo: el log se utiliza para representar y ordenar las trazas.

2.1.4. Validación del criterio de clasificación.

La clasificación del objetivo específico 1 se contrasta de forma independiente del modelo predictivo. Su validación frente a fugas de intensidad conocida se desarrolla en la sección 2.3. En conjunto, estos conceptos sustentan la clasificación de cada variable según su posición en la traza.

2.2. Algoritmos de clasificación y validación (objetivo específico 2).

El segundo objetivo específico compara el modelo base y el modelo corregido con tres algoritmos: regresión logística, como modelo lineal de referencia (Hosmer et al., 2013); Random Forest, como conjunto de árboles (Breiman, 2001); y XGBoost, como método de boosting de alto desempeño en datos tabulares (Chen y Guestrin, 2016). La comparación se realiza con validación cruzada anidada, porque la selección no anidada produce un sesgo optimista (Cawley y Talbot, 2010). En problemas con baja proporción de casos positivos, el espacio precisión-recall es más informativo que la curva ROC (Davis y Goadrich, 2006).

2.3. Detección de fugas mediante inyección controlada (objetivo específico 3).

El tercer objetivo específico contrasta el procedimiento de detección con variables que contienen una fuga inyectada de intensidad conocida. La inyección controlada de fallos se utiliza para evaluar la confiabilidad de sistemas de software (Natella et al., 2016); por analogía, se introduce una variable copia del desenlace con ruido controlado en tres niveles de intensidad. Hannun et al. (2021) proponen medir la fuga en modelos mediante información de Fisher, lo que ofrece un referente cuantitativo para este análisis. Las herramientas existentes (Yang et al., 2022; Alomar et al., 2025) revisan el código del pipeline y no la posición temporal de los atributos, por lo que el detector propuesto requiere una evaluación independiente.