Estado del arte

El aprendizaje supervisado consiste en entrenar un modelo con datos que ya contienen el resultado esperado, para que aprenda a predecir ese resultado en casos nuevos. En los modelos de predicción clínica, la validez de la evaluación depende de que cada variable de entrada esté disponible en el momento en que se realiza la predicción. Cuando se incluye información que sólo existe después del desenlace, el modelo aprende a reconocer el resultado y no a anticiparlo.

Este problema se conoce como fuga de información (leakage). **Kaufman et al. (2011)** lo formalizaron en minería de datos y propusieron estrategias para detectarlo y evitarlo. Posteriormente, **Kapoor y Narayanan (2023)** documentaron que la fuga afecta al menos a 294 artículos en 17 disciplinas, propusieron una taxonomía de ocho tipos y mostraron que, al corregirla, modelos complejos reportados como superiores dejan de superar de forma sustancial a métodos estadísticos más simples.

Sasse et al. (2025) presentaron una revisión de los escenarios de fuga en aprendizaje supervisado, mientras que **Rosenblatt et al. (2024)** cuantificaron empíricamente cómo la fuga por selección de variables y por sujetos repetidos infla el desempeño de los modelos predictivos. En el plano metodológico, **Kriegeskorte et al. (2009)** definieron el análisis circular (double dipping), y **Cawley y Talbot (2010)** demostraron el sesgo optimista que surge cuando la selección del modelo no está anidada dentro de la evaluación.

En cuanto a la detección automática, **Yang et al. (2022)** desarrollaron un análisis estático para identificar fugas en cuadernos de ciencia de datos, y **Alomar et al. (2025)** propusieron una herramienta de código abierto con el mismo fin. Estas herramientas detectan errores en el código del procesamiento, pero no evalúan si una variable es circular por su posición temporal respecto al desenlace.

Por otra parte, la minería de procesos ha sido aplicada en salud. **Rojas et al. (2016)** y **Aversano et al. (2025)** documentan su uso creciente para describir trayectorias de pacientes, verificar la conformidad con guías clínicas y detectar cuellos de botella. En el dominio de la sepsis, **Mannhardt y Blinde (2017)** analizaron las trayectorias de 1,050 pacientes de un hospital de Países Bajos, desde el registro en urgencias hasta el alta, y mostraron que la minería de procesos permite esclarecer el flujo de pacientes y contrastarlo con las guías clínicas. **Quintano Neira et al. (2020)** y **Silva Júnior et al. (2023)** aportan procedimientos sobre rutas clínicas de sepsis, y **Rebuge y Ferreira (2012)** y **Pereira et al. (2020)** describen metodologías replicables para proyectos de minería de procesos en hospitales.

Esta línea de investigación se centra en el descubrimiento y la conformidad del proceso ejecutado. No utiliza el orden de las trazas para decidir qué variables son legítimas como predictores, ni examina la circularidad de los atributos.

Así, la línea de fuga de información y la de minería de procesos en salud se han desarrollado de forma mayormente independiente. Ninguno de los trabajos revisados combina el orden temporal de un log de eventos con la detección de variables circulares en un modelo predictivo clínico, ni valida esa detección frente a fugas de intensidad conocida. La presente investigación se sitúa en esa intersección.

Planteamiento del problema

En los hospitales, los modelos predictivos que anticipan el ingreso de un paciente a la unidad de cuidados intensivos (UCI) se proponen como apoyo para el triaje y la asignación de recursos. Sin embargo, su desempeño reportado puede estar sobreestimado si el modelo utiliza variables circulares, es decir, variables que contienen información del propio desenlace que se intenta predecir.

Una variable es circular cuando define operacionalmente el desenlace (circularidad definicional), cuando se registra después del evento de interés y, por lo tanto, no está disponible en el momento de la predicción (circularidad temporal), o cuando actúa como sustituto fuerte del desenlace (circularidad proxy). Un modelo entrenado con estas variables mide en parte su propia consecuencia y no su capacidad real de anticipar la UCI.

Esta fuga de información es difícil de detectar en tablas convencionales, porque no suelen registrar el momento en que se obtuvo cada atributo. Los logs de eventos clínicos sí documentan el orden de las actividades y sus marcas de tiempo, por lo que permiten verificar si una variable se registró antes o después del ingreso a UCI. Sin embargo, ese orden rara vez se emplea para decidir qué predictores son legítimos.

El problema se delimita al log Sepsis Cases (Mannhardt, 2016), con 1,050 casos, 15,214 eventos y 110 casos con ingreso a UCI (cerca del 10 %), registrados en un hospital de Países Bajos entre noviembre de 2013 y junio de 2015. El problema a resolver es doble: desarrollar un procedimiento que detecte variables circulares a partir del orden temporal de las trazas, y cuantificar en qué medida la exclusión de esas variables modifica el desempeño de un modelo de ingreso a UCI.

Pregunta de investigación

¿En qué medida la exclusión de variables circulares influye en el desempeño predictivo del ingreso a UCI, en el log Sepsis Cases de un hospital de Países Bajos registrado entre noviembre de 2013 y junio de 2015?

Objetivo General

Analizar cómo la exclusión de variables circulares modifica el desempeño predictivo de un modelo de ingreso a UCI en un log de eventos de sepsis.

Objetivos específicos

• Examinar la posición temporal de cada variable respecto al ingreso a UCI dentro de cada traza, para clasificarla como circular o no circular.

• Cuantificar la diferencia de área bajo la curva (AUC) y de recall entre el modelo base y el modelo corregido, con validación cruzada anidada e intervalos de confianza por bootstrap.

• Contrastar la precisión y el recall del procedimiento de detección frente a variables con fuga inyectada de intensidad conocida.

Hipótesis

Excluir las variables circulares reduce el área bajo la curva (AUC) del modelo de ingreso a UCI respecto al modelo base, lo que indica que la circularidad infla el desempeño reportado en el log Sepsis Cases.

Hipótesis nula: no existe diferencia en el área bajo la curva entre el modelo base y el modelo corregido, más allá de la variación esperada por el muestreo.

La diferencia se estimará por algoritmo (regresión logística, Random Forest y XGBoost) con validación cruzada anidada repetida, y se acompañará de un intervalo de confianza por bootstrap. La hipótesis nula se rechazará cuando ese intervalo se ubique por completo por encima de cero. El recall, evaluado en un umbral de decisión fijado antes de los experimentos, se reportará como métrica complementaria.

Justificación

Relevancia social

La sepsis es una causa relevante de ingreso a las unidades de cuidados intensivos, y los modelos que anticipan ese ingreso pueden apoyar las decisiones de triaje desde urgencias **(Mannhardt y Blinde, 2017; Adjerid et al.,**

2023). Un modelo cuya precisión está inflada por circularidad puede orientar esas decisiones de manera errónea, al aparentar una capacidad de anticipación que no tendría en la práctica. Medir el efecto real de la circularidad contribuye a que los modelos utilizados en el triaje se evalúen con la información realmente disponible al momento de decidir.

Conveniencia

El estudio utiliza un log público y ya disponible, con un desenlace bien definido (Admission IC), por lo que no requiere acuerdos institucionales ni acceso a datos personales. Se apoya en herramientas abiertas como scikit-learn, XGBoost (Chen y Guestrin, 2016) y PM4Py (Berti et al., 2019). Su alcance, un log, un hospital y un desenlace, es ejecutable en el plazo de un programa de posgrado. Además, el orden de las actividades ofrece una vía sistemática para detectar la fuga, un problema reconocido como común en el aprendizaje automático (Kapoor y Narayanan, 2023).

Aporte teórico

La investigación vincula dos líneas que rara vez se cruzan: la literatura sobre fuga de información en aprendizaje automático y la minería de procesos en salud. Su contribución es un criterio operativo para clasificar variables según su posición en la traza respecto al desenlace. Este criterio distingue la circularidad definicional, temporal y proxy, y se valida tanto en un log real como en un log con fugas inyectadas de intensidad conocida.

Implicaciones prácticas

Si la corrección reduce el desempeño de forma relevante, los modelos reportados con este tipo de log podrían estar sobreestimados, lo que obligaría a revisar las métricas publicadas. El procedimiento es reutilizable en otros logs de eventos con desenlaces de ingreso o de alta. La validación con fugas inyectadas permite estimar la precisión y el recall del detector antes de aplicarlo a datos nuevos. Los resultados no son generalizables a otros hospitales sin una validación externa.

Marco Teórico

Este es el objetivo específico 1:

Examinar la posición temporal de cada variable respecto al ingreso a UCI dentro de cada traza, para clasificarla como circular o no circular.

2.1. Fuga de información y circularidad de variables en la predicción del ingreso a UCI.

El primer objetivo específico exige definir qué es una variable circular y establecer un criterio verificable para identificarla. Esta sección presenta los conceptos necesarios: la fuga de información, la clasificación de la circularidad y el uso del orden temporal de un log de eventos como criterio de medición.

2.1.1. Fuga de información en el aprendizaje supervisado.

Una fuga de información ocurre cuando un modelo utiliza, durante el entrenamiento o la evaluación, datos que no estarían disponibles en el momento de la predicción. Kaufman et al. (2011) la formalizaron en minería de datos, y Kapoor y Narayanan (2023) mostraron que es un problema extendido en la ciencia basada en aprendizaje automático. Su efecto es más grave en la evaluación, porque el desempeño reportado resulta mayor que el que el modelo tendría en la práctica.

2.1.2. Clasificación de la circularidad.

Una variable es circular cuando contiene información del propio desenlace. Se distinguen tres tipos:

• Circularidad definicional: la variable define operacionalmente el desenlace.

• Circularidad temporal: la variable se registra después del evento de interés y, por lo tanto, no está disponible en el momento de la predicción.

• Circularidad proxy: la variable actúa como sustituto fuerte del desenlace, aunque no lo defina ni se registre después de él.

La circularidad temporal es la única de las tres que puede verificarse directamente con las marcas de tiempo de un log. Las otras dos requieren evidencia documental sobre la definición de cada variable. Por ello, el criterio del objetivo específico 1 se aplica primero a la posición temporal y después se complementa con la documentación del log.

2.1.3. Log de eventos y posición temporal de los atributos.

Un log de eventos es un registro en el que cada evento corresponde a una actividad ejecutada en un caso, con su marca de tiempo y sus atributos. La secuencia ordenada de eventos de un caso constituye su traza (van der Aalst, 2016). Esta representación permite ubicar, para cada atributo, el momento en que se registró respecto al ingreso a UCI (Admission IC).

Con esta referencia, un valor de atributo se considera posterior al desenlace si su marca de tiempo es mayor que la marca de Admission IC del mismo caso. Un valor es elegible como predictor si su marca es menor o igual a la del momento de predicción, que en este estudio corresponde al registro en urgencias (ER Registration). El descubrimiento de modelos de proceso no forma parte de este objetivo: el log se utiliza para representar y ordenar las trazas.

2.1.4. Validación del criterio de detección.

Cuando la selección de variables no está anidada dentro del procedimiento de evaluación, el desempeño se sobreestima (Cawley y Talbot, 2010). Por ello, el criterio de clasificación del objetivo específico 1 se contrasta de forma independiente: en el objetivo específico 3, el procedimiento se evalúa con variables que contienen una fuga inyectada de intensidad conocida, siguiendo la lógica de la inyección controlada de fallos (Natella et al., 2016). Hannun et al. (2021) proponen medir la fuga en modelos mediante información de Fisher, y Davis y Goadrich (2006) muestran que, en problemas con pocos casos positivos, el espacio precisión-recall es más informativo que la curva ROC. Esto es relevante aquí, porque solo cerca del 10.5 % de los casos corresponde a ingreso a UCI.

En conjunto, estos conceptos sustentan la clasificación de cada variable según su posición en la traza y definen el criterio que se aplicará en el objetivo específico 1.